

Постановка аналитической задачи

Что такое аналитическая задача

- Аналитическая задача — это описание того, какой вопрос нужно решить с помощью данных.

В ней должны быть: пользователь результата, исследовательский вопрос, критерий успеха и подходящий датасет.

Без этих элементов анализ превращается в набор случайных графиков и метрик.

Четыре элемента постановки задачи

1. Кто будет использовать результат?
2. Какой вопрос мы хотим проверить или решить?
3. Как поймём, что результат полезен?
4. Какие данные нужны, чтобы ответить на вопрос?

Пользователь результата

Пользователь результата — это не всегда «заказчик».

Это человек или сущность, который будет принимать решение на основе анализа.

Примеры: преподаватель, менеджер продукта, врач, HR-специалист, руководитель отдела продаж.

Если пользователь не определён, трудно понять, какой вывод считать полезным.

Исследовательский вопрос

Исследовательский вопрос — это конкретный (проверяемый) вопрос, на который можно ответить с помощью данных.

Плохо

- «Проанализировать продажи»
- «Посмотреть, что влияет на успеваемость»
- «Сделать модель для клиентов»
- «Найти что-нибудь интересное»

Хорошо

- «Можно ли по активности студента за первые 3 недели предсказать риск несдачи?»
- «Какие признаки сильнее всего связаны с повторной покупкой?»
- «Отличаются ли группы клиентов по частоте заказов и среднему чеку?»

Критерий успеха

- Критерий успеха — это условие, по которому мы считаем результат достаточно полезным.
- Метрики оценки: accuracy, F1-score, MAE, MAPE...
- Прикладные значения: снизить число пропущенных проблемных случаев, ускорить проверку, уменьшить ручную работу.
- **Метрика без прикладного смысла редко убеждает пользователя результата.** Метрика != критерий успеха

Пример критерия успеха

- Задача: заранее находить студентов с риском несдачи курса.
- Пользователь: куратор или преподаватель.
- Плохой критерий: «получить высокую точность».
- Лучше: «найти не менее 70% студентов из группы риска при приемлемом числе ложных срабатываний».

Целевая переменная

- Целевая переменная — то, что мы хотим объяснить или предсказать.
- Для классификации это класс: сдал / не сдал, уйдёт / не уйдёт.
- Для регрессии это число: оценка, цена, спрос, время ожидания.
- Если целевой переменной нет, задача может быть описательной или поисковой.

Выбор подхода зависит от вопроса

- Если нужно описать текущее состояние — описательная аналитика.
- Если нужно объяснить связи — корреляции, статистический анализ, интерпретируемые модели.
- Если нужно предсказать класс — классификация.
- Если нужно предсказать число — регрессия.
- Если нужно найти группы — кластеризация.
- Если нужно предсказать будущее по времени — анализ временных рядов.

Наборы данных

- **Данные** — совокупность объективных сведений о каком-либо процессе или явлении.
- **Информация** — сведения, неизвестные ранее получателю, полезные для него, пополняющие его знания, подтверждающие или опровергающие соответствующие положения и убеждения. Информация носит субъективный характер и определяется уровнем знаний субъекта и степенью его восприятия. Информация извлекается субъектом из соответствующих данных.
- **Знания** — совокупность данных (фактов) и связывающих их правил.

Различные формы и методы исследования данных


- нахождение ассоциаций, связанных с привязкой к какому-либо событию;
- нахождение последовательностей событий во времени;
- нахождение скрытых закономерностей по наборам данных путем определения причинно-следственных связей между значениями определенных косвенных параметров исследуемого объекта (ситуации, процесса);
- оценка важности (влияния) параметров на события и ситуации;
- классифицирование (распознавание), осуществляемое путем поиска критериев, по которым можно было бы относить объект (события, ситуации, процессы) к той или иной классификационной категории;
- кластеризация, основанная на группировании объектов по каким-либо признакам;
- прогнозирование событий и ситуаций. Следует упомянуть неоднородность (разнородность) информационных ресурсов, характерную для многих предметных областей.

- **Датасет (Dataset)** -- это коллекция данных, представленная в структурированном виде


# Hours_Stu... ≡	# Attendance ≡	▲ Parental_I... ≡	▲ Access_to... ≡	✓ Extracurri... ≡	# Sleep_Hours ≡	# Previous_... ≡
23	84	Low	High	No	7	73
19	64	Low	Medium	No	8	59
24	98	Medium	Medium	Yes	7	91
29	89	Low	Medium	Yes	8	98
19	92	Medium	Medium	Yes	6	65
19	88	Medium	Medium	Yes	8	89
29	84	Medium	Low	Yes	7	68
25	78	Low	High	Yes	6	50
17	94	Medium	High	No	6	80

Структура датасетов

- **Строки** -- это один объект или одно наблюдение
- **Столбцы** -- это признаки или свойства, которые мы описываем.
В статистике их часто называют переменными
- **Ячейка (значение)** -- это конкретное значение признака для конкретного объекта



Типы данных внутри датасета



```
graph TD; A[Типы данных внутри датасета] --> B[Категориальные данные]; A --> C[Количественные (числовые) данные];
```

Категориальные данные

Количественные (числовые)
данные

Понятие «грязные данные»

- **Пропуски:** пустые клетки в таблице.
 - **Выбросы/Аномалии:** значения, которые сильно выбиваются из общего ряда.
 - **Дубликаты:** одна и та же строка встречается дважды.
 - **Несогласованность:** формально одно и то же значение может быть записано разным образом.
-
- *Выброс -- это статистическое понятие*
 - *Аномалия -- это контекстное или поведенческое понятие*

Метаданные

- **Метаданные** -- это «данные о данных»
- Обычно включают:
 - Название
 - Автор
 - Дата создания
 - Описание колонок
 - Источник

Если датасет "кривой", то и выводы будут "кривыми"
("Garbage In, Garbage Out")

Как выбирать датасет

1. Есть ли в нём нужный объект анализа?
2. Есть ли признаки, связанные с вопросом?
3. Есть ли целевая переменная, если задача предсказательная?
4. Достаточно ли строк для вывода?
5. Понятно ли происхождение и описание колонок?
6. Можно ли использовать данные этически и законно?

Этап 1.

- Файл PDF или DOCX на 1–2 страницы.
- Название датасета и ссылка на источник:
 1. Название датасета.
 2. Источник и автор.
 3. Что является строкой.
 4. Какие есть признаки.
 5. Есть ли целевая переменная.
 6. Сколько строк и столбцов.
 7. Какие есть ограничения и риски.
- Постановка аналитической задачи по шаблону (4 вопроса).
- Краткое описание структуры датасета: строки, столбцы, целевая переменная.
- Критерий успеха и выбранный аналитический подход.
- Вывод: подходит ли датасет для задачи и почему.